

Anwenderdokumentation

Lokale KI-Sprachassistent

Inhaltsverzeichnis

1. Einleitung	1
1.1. Projektübersicht	1
1.2. Zielgruppe	1
2. Systemanforderungen	2
2.1. Hardware	2
2.2. Software	2
2.3. Empfohlene Softwarepakete	2
3. Installation des Servers	3
3.1. Repository klonen	3
3.2. Virtuelle Umgebung für den Server erstellen und aktivieren	3
3.3. Installation aller Pakete	3
3.4. Download der trainierten Modelle	3
3.5. Installation von Playwright	4
3.6. Installation von Ollama	4
3.7. Optionale Installation von Torch	5
3.8. Mikroservices starten	5
4. Client Setup	7
4.1. Repository klonen	7
4.2. Virtuelle Umgebung für den Client erstellen und aktivieren	7
4.3. Installation aller Pakete	7
4.4. Optionale Installation von Torch	8
4.5. Starte das Engine-Skript:	8
5. Aufruf der einzelnen Internetsuchen	9
5.1. To-Do-Intent	9
5.2. Wikipedia-Intent	9
5.3. YouTube-Intent	9
5.4. Studienordnung-Intent	10
5.5. Wetter-Intent	10
5.6. Uhrzeit-Intent und Datum-Intent	10
5.7. Suchmaschinen-Intent	10
6. Fine-Tuning	11
6.1. Aktivierungswort-KI (Client-Seite)	11
6.2. Textklassifizierung-KI (Server-Seite)	11
7. FAQ	12
7.1. Kann der Assistent auf Rückfragen antworten?	12
7.2. Kann ich Einträge in meiner To-Do-Liste ändern oder müssen diese erneut angelegt werden?	12
7.3. Warum braucht der Assistent so lange, um meine Anfrage zu beantworten?	12

7.4. Wie kann ich ein anderes Aktivierungswort auswählen?	12
7.5. Benötige ich eine Internetverbindung?	12
7.6. Warum bekomme ich falsche Antworten?	12

1. Einleitung

1.1. Projektübersicht

Im Fokus des Projektes „Lokaler KI-Sprachassistent“ stand die Entwicklung eines Sprachassistenten. Dieser soll nur lokale Ressourcen nutzen, um Problem wie den Datenschutz zu umgehen. Der Sprachassistent nutzt Künstliche Intelligenz, um die Nutzeranfragen zu bearbeiten und auf diese zu antworten. Dabei werden 4 Kategorien abgedeckt: Anfragen an Wikipedia, Anfragen an YouTube, Anfragen, die mit Hilfe einer PDF, in diesem Fall eine Studienordnung, beantwortet werden, sowie Wetteranfragen. Ebenfalls ist es möglich eine To Do Liste zu erstellen und auf diese zuzugreifen und sie zu bearbeiten.

1.2. Zielgruppe

Diese Dokumentation ist für Anwender des lokalen KI-Sprachassistenten gedacht, die den Sprachassistenten lokal installieren und nutzen wollen.

2. Systemanforderungen

2.1. Hardware

2.1.1. Client (empfohlen)

- Prozessor: Intel Core i3 oder besser
- GPU: NVIDIA GT 1030 oder besser
- RAM: 4 GB
- freier Speicherplatz: 3 GB

2.1.2. Server (empfohlen)

- Prozessor: Intel Core i7 oder besser
- GPU: NVIDIA RTX 2060 oder besser
- RAM: 32 GB oder mehr
- freier Speicherplatz: 25 GB oder mehr

2.2. Software

- Betriebssystem: Windows, macOS oder Linux
- Python: Version 3.11.x (ab Python 3.12 ist TTS nicht kompatibel)
- Ollama: Für die Integration des LLM-Modells erforderlich
- Playwright: Ermöglicht Webautomatisierung, z. B. für YouTube- oder Google-Suchen.

2.3. Empfohlene Softwarepakete

- Torch (CUDA): Optional für GPU-Beschleunigung; wird für schnellere Verarbeitung bei Modellen empfohlen.

3. Installation des Servers

Bei dem Sprachassistenten handelt es sich um eine Konsolenanwendung. Das heißt alle in der folgenden Anleitung genannten Befehle müssen im Terminal aufgerufen werden.

3.1. Repository klonen

```
git clone -b Nathaniel https://github.com/anastasia98s/PS2.git assistant_ai
```

3.2. Virtuelle Umgebung für den Server erstellen und aktivieren

In das Server Verzeichnis wechseln

```
cd assistant_ai\server
```

Virtuelle Umgebung erstellen

```
python -m venv assistant_ai_server
```

Hinweis: Es tritt keine Bestätigung auf, dass die Virtuelle Umgebung erstellt wurde.

Virtuelle Umgebung aktivieren

```
assistant_ai_server\Scripts\activate
```

Hinweis: Bei korrekter Aktivierung steht nun "(assistant_ai_server)" vor dem Eingabe-Prompt.

3.3. Installation aller Pakete

Alle erforderlichen Pakete sind in der `requirements.txt` festgehalten und können manuell installiert werden.

```
pip install -r requirements.txt
```

3.4. Download der trainierten Modelle

1. Textklassifizierungsmodell:

- Laden Sie die Datei `textklassifizierung_modell.zip` von <https://drive.google.com/drive/folders/1I27FN5USWLdT6kTXWMWGypIN0eeF8oru> herunter.

- Extrahieren Sie die Datei und legen Sie den Ordner `data` im Verzeichnis `server/system/textklassifizierung` ab.

2. Text-to-Speech-Modell:

- Laden Sie die Datei `text_to_speech_modell.zip` von <https://drive.google.com/drive/folders/1I27FN5USWLdT6kTXWMWGypIN0eeF8oru> herunter.
- Extrahieren Sie die Datei und legen Sie den Ordner `data` im Verzeichnis `server/system/text_to_speech` ab.

3.5. Installation von Playwright

Playwright ist ein Open-Source-Tool zur Webautomatisierung. Es wird vom KI-Sprachassistenten verwendet, um effizient Webseiten wie YouTube oder Wikipedia zu durchsuchen.

3.5.1. Installation

Nach der Paketinstallation muss Playwright manuell mit folgendem Befehl installiert werden:

```
playwright install
```

3.6. Installation von Ollama

Ollama ist ein Tool zur Verwaltung von Large Language Models (LLMs). Es ermöglicht den Zugriff auf und die Nutzung von LLM-Modellen, die für die Verarbeitung von Anfragen im Sprachassistenten erforderlich sind.

3.6.1. Installation

1. Lade Ollama von <https://ollama.com/download> herunter.
2. Folge den Installationsanweisungen auf der Website, um das Tool auf deinem Betriebssystem zu installieren.

3.6.2. Modellinstallation

Nachdem Ollama installiert ist, musst du das LLM-Modell `llama3.2:latest` hinzufügen, um die gewünschten Funktionalitäten des Sprachassistenten zu ermöglichen.

```
ollama pull llama3.2:latest
```

3.6.3. Überprüfung der Installation

Überprüfe, ob Ollama korrekt installiert wurde, indem du folgenden Befehl in der Kommandozeile ausführst:

```
ollama -v
```

Bei korrekter Installation wird die aktuelle Version angezeigt.

3.7. Optionale Installation von Torch

Torch ist eine leistungsstarke Machine-Learning-Bibliothek, die vom KI-Sprachassistenten für KI-Modelle genutzt wird. Sie ermöglicht GPU-Unterstützung und beschleunigt die Verarbeitung großer Modelle. Die Installation von Torch ist optional, wird aber empfohlen, wenn dein System eine dedizierte GPU besitzt.

3.7.1. Installation

Um Torch mit GPU-Unterstützung (CUDA) zu installieren, führen Sie den folgenden Befehl aus (Windows):

```
pip install torch torchvision torchaudio --index-url  
https://download.pytorch.org/whl/cu124
```

- Die Installation von Torch mit GPU-Unterstützung ist optional, ermöglicht jedoch eine deutlich schnellere Verarbeitung, falls eine Nvidia-GPU verfügbar ist.
- Falls keine GPU vorhanden ist, verwendet Torch automatisch die CPU. Dies kann jedoch zu deutlich längeren Verarbeitungszeiten führen.

3.8. Mikroservices starten

3.8.1. Main-Server-Service

Zuerst muss der Main-Server-Service gestartet werden. Dazu wechseln Sie in das Verzeichnis `main_server`, in dem sich die Datei `main.py` befindet.

```
python main.py ^  
  --main_server_ip <main_server_ip> --main_server_port <main_server_port> ^  
  --kontoverwaltung_ip <kontoverwaltung_ip> --kontoverwaltung_port  
<kontoverwaltung_port> ^  
  --textklassifizierung_ip <textklassifizierung_ip> --textklassifizierung_port  
<textklassifizierung_port> ^  
  --speech_to_text_ip <speech_to_text_ip> --speech_to_text_port <speech_to_text_port>  
^  
  --text_to_speech_ip <text_to_speech_ip> --text_to_speech_port <text_to_speech_port>  
^  
  --datum_intent_ip <datum_intent_ip> --datum_intent_port <datum_intent_port> ^  
  --uhrzeit_intent_ip <uhrzeit_intent_ip> --uhrzeit_intent_port <uhrzeit_intent_port>  
^  
  --wetter_intent_ip <wetter_intent_ip> --wetter_intent_port <wetter_intent_port> ^
```

```
--wikipedia_intent_ip <wikipedia_intent_ip> --wikipedia_intent_port  
<wikipedia_intent_port> ^  
--studienordnung_intent_ip <studienordnung_intent_ip> --studienordnung_intent_port  
<studienordnung_intent_port> ^  
--todolist_intent_ip <todolist_intent_ip> --todolist_intent_port  
<todolist_intent_port> ^  
--search_engine_intent_ip <search_engine_intent_ip> --search_engine_intent_port  
<search_engine_intent_port> ^  
--youtube_intent_ip <youtube_intent_ip> --youtube_intent_port <youtube_intent_port>
```

3.8.2. Weitere Services (außer dem Main-Server)

```
python main.py --main_server_ip <main_server_ip> --main_server_port <main_server_port>
```

3.8.3. Hinweis:

- Es gibt 13 Microservice.
- Der erste Microservice, der gestartet werden muss, ist der Main-Server-Service.
- Der zweite Microservice, der gestartet werden muss, ist der Kontoverwaltung-Service.
- Um alle Microservices einfacher zu starten, können Sie die Datei **start.bat** ausführen. Diese startet die Services auf den Ports **8000** bis **8012** auf **localhost**.

4. Client Setup

4.1. Repository klonen

Dieser Schritt kann übersprungen werden, wenn Server und Client auf demselben Gerät laufen

```
git clone -b Nathaniel https://github.com/anastasia98s/PS2.git assistant_ai
```

4.2. Virtuelle Umgebung für den Client erstellen und aktivieren

In das Client Verzeichnis wechseln

```
cd assistant_ai\client
```

Virtuelle Umgebung erstellen

```
python -m venv assistant_ai_client
```

Virtuelle Umgebung aktivieren

```
assistant_ai_client\Scripts\activate
```

4.3. Installation aller Pakete

Alle erforderlichen Pakete sind in der requirements.txt fetsgehalten und werden mithilfe dieser manuell installiert.

```
pip install -r requirements.txt
```

4.3.1. Installation von Playwright

Playwright ist ein Open-Source-Tool zur Webautomatisierung. Es wird vom KI-Sprachassistenten verwendet, um effizient Webseiten wie YouTube oder Wikipedia zu durchsuchen.

4.3.2. Installation

```
playwright install
```

4.4. Optionale Installation von Torch

Torch ist eine leistungsstarke Machine-Learning-Bibliothek, die vom KI-Sprachassistenten für KI-Modelle genutzt wird. Sie ermöglicht GPU-Unterstützung und beschleunigt die Verarbeitung großer Modelle. Die Installation von Torch ist optional, wird aber empfohlen, wenn dein System eine dedizierte GPU besitzt.

4.4.1. Installation

Um Torch mit GPU-Unterstützung (CUDA) zu installieren, führen Sie den folgenden Befehl aus (Windows):

```
pip install torch torchvision torchaudio --index-url  
https://download.pytorch.org/whl/cu124
```

- Die Installation von Torch mit GPU-Unterstützung ist optional, ermöglicht jedoch eine deutlich schnellere Verarbeitung, falls eine Nvidia-GPU verfügbar ist.
- Falls keine GPU vorhanden ist, verwendet Torch automatisch die CPU. Dies kann jedoch zu deutlich längeren Verarbeitungszeiten führen.

4.5. Starte das Engine-Skript:

```
python engine.py
```

Geben Sie anschließend die **IP-Adresse** und den **Port** des Main-Server-Services ein, wenn Sie dazu aufgefordert werden.

4.5.1. Assistenten aufrufen

Nun kann der Assistent nach belieben aufgerufen werden

Standardaktivierungswort: **Tim**

1. Benutzer: Hey Tim
2. Assistent: Ja
3. Benutzer: **Befehl eingeben**

4.5.2. Hinweis

- Falls die Spracherkennung zu empfindlich ist, können Sie den Wert **AUDIO_THRESHOLD** in der Datei **config.json** anpassen. Je höher der Wert, desto weniger empfindlich reagiert das System.
- Sollte das Standardaktivierungswort nicht zuverlässig erkannt werden, können Sie das Aktivierungswort-Modell in der Datei **setting.py** mit Ihrer eigenen Stimme finetunen, um die Erkennungsgenauigkeit zu verbessern.

5. Aufruf der einzelnen Internetsuchen

Der Assistent ist derzeit auf folgende Anwendungsmöglichkeiten, sogenannte Intents, trainiert:

- Anlegen einer To-Do Liste
- Abfragen von Einträgen der To-Do Liste
- Ändern und Löschen der Einträge auf der To-Do Liste
- Wetterabfragen
- Uhrzeitabfragen
- Wikipedia-Abfragen
- YouTube Videos suchen lassen
- Abfragen zu einer PDF, hier die Studienordnung, sowie die Prüfungsordnung der HTW Dresden im Wirtschaftsinformatik Bachelor, Version 2010
- Abfragen über eine Suchmaschine

Im Folgenden findest du einige Beispiele, wie die einzelnen Funktionen aufgerufen werden können.

5.1. To-Do-Intent

Der To-Do-Intent lässt es zu persönliche To-Dos zu erstellen, ändern, abzufragen und löschen.

To-Do erstellen - Trage ein Meeting heute um 12:30 Uhr ein. - Kannst du den Tennisunterricht nächste Woche Donnerstag um 17:00 Uhr eintragen?

To-Do ändern - Verschiebe den Meetingtermin von 12:30 Uhr auf 13:00 Uhr. - Ändere das Ereignis nächste Woche Donnerstag in Tanzunterricht.

To-Do abfragen - Was habe ich nächste Woche Donnerstag vor? - Nenne mir alle Termin von heute.

To-Do löschen - Lösche das Meeting heute. - Kannst du den Tanzunterricht absagen?

5.2. Wikipedia-Intent

Der Wikipedia-Intent ermöglicht es Wikipedia-Artikel zu durchsuchen und zusammenzufassen.

Beispiel Wikipedia-Abfrage - Wer ist Barrack Obama? - Was versteht man unter Demokratie? - Gib mir Informationen zur Nebelkrähe.

5.3. YouTube-Intent

Der YouTube-Intent ermöglicht das gezielte Suchen von YouTube-Videos, sowie Abspielen dieser.

Beispiel YouTube-Abfrage - Finde ein Video über gesunde Ernährung. - Suche nach Musik von Beethoven auf YouTube.

5.4. Studienordnung-Intent

Der Studienordnung-Intent ermöglicht es Fragen anhand der Studienordnung und Prüfungsordnung des Studiengangs Wirtschaftsinformatik der HTW Dresden zu beantworten. Die Informationen beziehen sich auf die Studienordnung und Prüfungsordnung Version 2010.

Beispiel Studienordnung-Intent - Wie viel Zeit habe ich für meine Bachelorarbeit? - Was ist ein Freiversuch?

5.5. Wetter-Intent

Der Wetter-Intent ermöglicht Abfragen zum Wetter

Beispiel Wetter-Intent - Wie ist das Wetter am 11.12. um 12 Uhr? - Zeig mir das Wetter für heute Abend in New York.

5.6. Uhrzeit-Intent und Datum-Intent

Durch das Uhrzeit- und Datums-Intent lassen sich das aktuelle Datum und die Uhrzeit abfragen.

Beispiel Uhrzeit-Intent und Datum-Intent - Welche Uhrzeit haben wir? - Wie spät ist es? - Welches Datum ist morgen?

5.7. Suchmaschinen-Intent

Das Suchmaschinen-Intent erlaubt Internetsuchen über DuckDuckGo.

Beispiel Suchmaschinen-Internet - Vegane Lasagne Rezept - Finde Tickets für das Musical Hamilton in London.

6. Fine-Tuning

6.1. Aktivierungswort-KI (Client-Seite)

1. **Starten der Einstellungen:** Führen Sie das Skript `setting.py` aus, um die Konfiguration zu starten.
2. **IP und Port eingeben:** Geben Sie die IP-Adresse und den Port des Hauptservers ein.
3. **Aktivierungswort aufnehmen:** Wählen Sie die Option "Aktivierungswort aufnehmen", um das Aktivierungswort für die KI zu erfassen.
4. **Aktivierungswort-KI Training:** Trainieren Sie die KI mit dem aufgenommenen Aktivierungswort.
5. **Aktivierungswort bereit:** Nach dem Training ist das Aktivierungswort einsatzbereit und kann verwendet werden.

6.2. Textklassifizierung-KI (Server-Seite)

1. **Starten der Einstellungen:** Führen Sie das Skript `setting.py` mit den Parametern `--main_server_ip <main_server_ip>` und `--main_server_port <main_server_port>` aus.
2. **Datenkontrolle:** Überprüfen und verwalten Sie die Daten, die für das Training der Textklassifizierung verwendet werden.
3. **KI-Training:** Trainieren Sie die KI mit den vorbereiteten Daten.
4. **Textklassifizierung bereit:** Nach dem Training ist die Textklassifizierung einsatzbereit und kann verwendet werden.

6.2.1. Verwendung der GUI für Datenkontrolle

1. **Datensatz eingeben:** Geben Sie einen Satz oder Text als Datensatz ein.
2. **Text aufteilen:** Verwenden Sie die Funktion "Split", um den Text in kleinere Einheiten zu unterteilen.
3. **Anmerkung hinzufügen:** Fügen Sie die passende Anmerkung zum Datensatz hinzu.
4. **Absicht und Szenario eingeben:** Geben Sie die entsprechende Absicht und das Szenario ein, die zum Datensatz passen.
5. **Hochladen:** Laden Sie den bearbeiteten Datensatz hoch.

Hinweis

- Sie können bereits hochgeladene Daten aktualisieren.
- Die Absichten, Anmerkungen oder Szenarien auf Seite 2 der GUI anpassen.

7. FAQ

7.1. Kann der Assistent auf Rückfragen antworten?

Nein, der Assistent ist derzeit nicht darauf ausgelegt, auch Rückfragen zu antworten. Der Nutzer muss für weitere Anfragen erneut das Aktivierungswort nutzen.

7.2. Kann ich Einträge in meiner To-Do-Liste ändern oder müssen diese erneut angelegt werden?

Deine KI ist aktuell nicht darauf trainiert, Einträge in der To-Do-Liste zu ändern. Sie unterstützt nur das Hinzufügen, Löschen und Abfragen von Einträgen. Wenn du etwas ändern möchtest, musst du den alten Eintrag löschen und einen neuen hinzufügen.

7.3. Warum braucht der Assistent so lange, um meine Anfrage zu beantworten?

- **Hardware:** Die Verarbeitung auf einer CPU ist langsamer als auf einer leistungsstarken GPU.
- **Netzwerk:** Wenn der Assistent über eine API oder einen entfernten Server läuft, kann die Antwortzeit durch die Netzwerkverbindung beeinflusst werden.

7.4. Wie kann ich ein anderes Aktivierungswort auswählen?

Um ein neues Aktivierungswort festzulegen, muss zunächst die Datei `aktivierungswort.pth` gelöscht werden. Anschließend ist die `settings.py` auf der Client-Seite zu öffnen, um eine neue Aktivierungsstimme aufzunehmen und das Modell entsprechend neu zu trainieren.

7.5. Benötige ich eine Internetverbindung?

Nein, prinzipiell benötigst du keine Internetverbindung, um den Assistenten zu nutzen, da dieser für den lokalen Betrieb ausgelegt ist. Für einige Funktionen wie Wikipedia und YouTube-Suchen, benötigst du jedoch eine Internetverbindung.

7.6. Warum bekomme ich falsche Antworten?

Der Assistent kann nur auf Basis der vorhandenen Daten antworten. Sind die Daten nicht vollständig oder korrekt, so liegt dies vermutlich an den Trainingsdaten und diese müssen angepasst werden. Ein weiterer möglicher Grund könnte sein, dass das Speech-to-Text-Modul fehlerhafte Eingaben hat, wenn die gesprochene Sprache nicht korrekt erkannt wurde. Dies kann durch die Limitationen von Whisper bedingt sein, welches in bestimmten Akzenten oder Umgebungsgeräuschen nicht immer präzise arbeitet.